Data Science HW1

B10915030 陳奕軒

1. 引入會用到的 library

```
#Essential
import pandas as pd
import numpy as np

#EDA
import seaborn as sns
from matplotlib import pyplot as plt

#Pipeline
from sklearn.pipeline import Pipeline
from imblearn.pipeline import Pipeline as imbPipeline
from sklearn.compose import ColumnTansformer

#Preprocess
from sklearn.impute import SimpleImputer
from sklearn.rimpute import SimpleImputer
from sklearn.preprocessing import OneHotEncoder, StandardScaler, OrdinalEncoder

#Up & down sampling for unbalanced data
from imblearn.combine import SMOTETomek

#Model

#Model
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import LogisticRegression

#Model selection
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import GridSearchCV
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import fl_score
```

2. 資料前處理

i. 資料輸入

```
train = pd.read_csv('../input/2022-data-science-hw1/train.csv')
test = pd.read_csv('../input/2022-data-science-hw1/tst.csv')
```

ii. 特徵選擇

```
features = train.columns[0: 16].tolist()
print('Selected features=')
print(features)

train_data = train[features]

#Yes/No to 1/0
y = train['Attribute17'].map({'Yes': 1, 'No': 0})
```

X 暫時選擇 Feature1~16

Y 為 Feature17

iii. 觀察資料是否平衡

```
y.value_counts()

0 13965
1 3138
Name: Attribute17, dtype: int64
```

由以上得知資料不平衡,需要特殊處理。

- iv. 特殊狀況處理
 - Attribute1 日期

```
#Divide by '-'
dateTime = pd.DatetimeIndex(train_data['Attribute1'])
#Train
#Year
train_data['Year'] = dateTime.year
train_data['Year'] = train_data['Year'].astype(str)
#Wonth
train_data['Month'] = dateTime.month
train_data['Month'] = train_data['Month'].astype(str)
#Drop
train_data.drop('Attribute1', axis=1, inplace=True)

#Divide by '-'
dateTime = pd.DatetimeIndex(test['Attribute1'])
#Train
#Year
test['Year'] = dateTime.year
test['Year'] = dateTime.year
test['Year'] = dateTime.month
test['Month'] = test['Month'].astype(str)
#Drop
test.drop('Attribute1', axis=1, inplace=True)
```

取出年份、月份作為特徵,並刪除原本日期。

● Attribute2 氣象站地區

```
#Train
#train_data['Attribute2'] = train_data['Attribute2'].astype(str)
train_data.drop(['Attribute2'], axis=1)
#Test
#test['Attribute2'] = test['Attribute2'].astype(str)
test.drop(['Attribute2'], axis=1)
```

因為地區特徵值種類過多且不平均,所以刪除。

● Attribute14 下午三點,雲層遮蓋天空的比例

```
#Train
train_data['Attribute14'] = train_data['Attribute14'].astype(str)
#Test
test['Attribute14'] = test['Attribute14'].astype(str)
```

將原本的 numerical feature 轉換為 categorical feature, 因為

地區並不是數值,比較像 Encode 後的結果。

v. 分類

根據 Feature 的 dtype,將他們分類為 Numerical column 和

Categorical column ·

3. 定義前處理器

```
# 數個的處理
# Fill na with median
# Use scaler to norm
numerical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler()) #comment if using randomforest
])
# 分類的處理
# Fill na with most_frequent
# Using label encoder
categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='most_frequent')),
    #('encoder', OrdinalEncoder(handle_unknown='use_encoded_value', unknown_value=-1))
    ('encoder', OneHotEncoder(handle_unknown='ignore'))
])
# 初處理修在一起
preprocessor = ColumnTransformer(
    transformers=[
        ('num', numerical_transformer, numerical_cols),
        ('cat', categorical_transformer, categorical_cols)
])
```

為了簡化流程和程式碼,所以採用 pipeline 做為處理數值的方法。這邊定

義兩個類別的前處理器:

- Numerical:使用中位數填補 null value。
- Categorical:採用 One hot Encoder,並忽略沒看過的值。

4. 尋找最佳的超參數

i. 定義流程

```
my_pipeline = imbPipeline(steps=[
    ('preprocessor', preprocessor),
         ('UpSample & DownSample', SMOTETomek(random_state=1)),
         ('model', RandomForestClassifier(random_state=1))
])


my_pipeline = imbPipeline(steps=[
         ('preprocessor', preprocessor'),
         ('UpSample & DownSample', SMOTETomek(random_state=1)),
         ('model', KNeighborsClassifier())
])

my_pipeline = imbPipeline(steps=[
         ('preprocessor', preprocessor'),
         ('UpSample & DownSample', SMOTETomek(random_state=1)),
         ('upsample & DownSample', SMOTETomek(random_state=1)),
         ('upsample & DownSample', SMOTETomek(random_state=1)),
         ('model', LogisticRegression(max_iter=1000))
])
```

這裡我測試了不同的 Classifier: Random forest classifier, KNN, Logistic regression。基於 kaggle 和 local 上的 score,我選用 Logistic 和 Random forest。這兩種 Classifier 都使用了前面定義的 preprocessor、SMOTETomek (同時進行 up sample 和 down sample 的工具)。

● Random forest 簡介:


Random Forest Classifier



如圖·Random forest 由多個 Decision tree 組成·每個 tree 都 負責判斷不同的 variable·該 model 透過隨機的方式決定哪個 tree

得到哪些 data。

• Logistic regression 簡介:



如圖,該 model 會在資料點上找到一條線,來切分兩種不同的

class,資料比較靠近誰就分到哪類。

ii. 網格搜索

● 候選超參數

```
param_grid = {
    'model__n_estimators': [300, 350, 400, 450, 500],
    'model__max_features': ['auto', None, 'log2'],
    'model_max_depth': [3, 4, 5, 6, 7],
    'model_criterion' :['gini', 'entropy']
)|
param_grid = {
    'model__n_neighbors': [3, 4, 5, 6, 7]
}
```

■ RandomForest:

◆ n_estimators:森林中樹木的數量

◆ max_features: 考慮 feature 的數目

◆ max_depth:最大深度

◆ criterion: 衡量 split 後的品質的方法

■ KNN:

- ◆ n_neighbors:一次選擇多少鄰近值
- Logistic
 - ◆ None
- Fit

```
#cv -> StratifiedKFold
#grid = GridSearchCV(my_pipeline, param_grid=param_grid, cv=5, scoring='f1')
grid = GridSearchCV(my_pipeline, param_grid=param_grid, cv=5, scoring='accuracy')
grid_result = grid.fit(X, y)
```

我們使用上面建立的流程,並從定義好的超參數範圍進行搜

索,衡量的指標有兩種版本,一種以F1 score (結合精準度、召

回率)做為衡量指標,另一種為直觀的準確度。

● 最佳 hyper parameter

```
#print(f'最佳F1值:{grid_result.best_score_},最佳多數組合:{grid_result.best_params_}')
print(f'最佳準確值:{grid_result.best_score_},最佳多數組合:{grid_result.best_params_}')
```

Random Forest:

註:此處應為 Accuracy (typo)

KNN:

```
最佳F1值:0.4819047203196529,最佳參數組合:{'model__n_neighbors':6}
```

● 模型

為求提交方便,所以直接從 best_params_屬性內獲得資

訊·並註解掉 GridsearchCV。如果日後要使用模型的話需要直

接修改參數,避免冗長的找參數過程。

● 訓練&預測

```
my_pipeline.fit(X, y)

result = my_pipeline.predict(test_X)
```

● 輸出

輸出為 CSV 檔。

5. 如何執行

Random Forest

■ 註解 scaler

■ 取消 Random Forest 的註解並註解其他 code

■ 取消 Random Forest 的註解並註解其他 code,同時使用建

議的 Hyperparameter

- Logistic Regression
 - 維持原樣即可